宏动作奖励计算与信用分配时机

① 宏动作执行：一次策略决策，连续五个同语义基元编辑

宏状态 s_t

语义 Actor $a_t \sim \pi_\theta(a|s_t)$

宏动作 M_t：五条边共享同一语义动作 a_t

$e_{t,1}$ a_t → $e_{t,2}$ a_t → $e_{t,3}$ a_t → $e_{t,4}$ a_t → $e_{t,5}$ a_t

查询受害检测器
仅在第5条边之后

新状态 s_{t+1}

终止判断 d_t

不进行逐边查询；宏奖励不拆分为 $r_t/5$，五个基元编辑共同获得一次联合反馈

$s_t(v)$，$s_{t+1}(v)$，τ

② 奖励计算：只使用检测器可观察分数、固定阈值与编辑数量

分数变化奖励 / 惩罚

$$r_{score} = \mathrm{clip}\left(\frac{s_t(v) - s_{t+1}(v)}{\max(|s_t(v)|, |\tau|, \varepsilon)}, -1, 1\right)$$

跨阈值奖励

$$r_{cross} = \mathbb{I}[s_t(v) \geq \tau > s_{t+1}(v)]$$

无标签间接影响

$$r_{ind} = 0.5\,\mathrm{mean}(\mathrm{Top5}(\Delta s_i^+)) + 0.5\tanh(N_{ind_cross}/2)$$

编辑成本惩罚

$$r_{edit} = \Delta E_t / L$$

宏动作总奖励

$$r_t = 1.0 r_{score} + 0.5 r_{cross} + 0.2 r_{ind} - 0.05 r_{edit}$$

在线奖励不读取 metadata 真值；间接项只观察未被直接攻击的初始告警

③ 信用分配：宏内联合归因，宏间通过GAE传播，目标间相互隔离

一个宏 transition
$(s_t,\ a_t,\ r_t,\ s_{t+1},\ d_t)$

宏 rollout
累计8个transition

GAE优势估计

$$\delta_t = r_t + \gamma V(s_{t+1})(1 - d_t) - V(s_t)$$

$$A_t = \delta_t + \gamma\lambda(1 - d_t)A_{t+1}$$

PPO更新
Actor + Critic

同一目标：后续宏奖励以 $\gamma\lambda$ 折扣回传 ｜ 目标边界：$d_t = 1$，奖励不传播到下一目标

PPO只更新语义动作 a_t 的概率；五个候选端点由确定性合法选择器生成，不单独接收梯度。